嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：Olist 电商用户价值与留存可视化分

学　　院：数据科学学院

专业班级：大数据 241

学　　号：2024459985110

姓　　名：陈丹

完成日期：11 月 1 日

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；② README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

数 据 科 学 学 院

Olist 电商用户价值与留存可视化分析

作者：大数据 241 陈丹

（嘉兴大学 数据科学学院）

摘要：本文以 Kaggle 公开发布的 Olist 巴西电商数据集为对象，使用 Python 技术栈完成数据获取、清洗治理、模型分析与可视化大屏的端到端商业数据分析流程。数据涵盖 99441 笔订单与 9 张关联表，经清洗与多表关联构建 26 列宽表。应用 RFM、同期群留存、帕累托/ABC、环比同比与移动平均、SARIMA 预测五种模型，发现重要价值客户 1336 人贡献 3.0% 销售额，A 类 12 个品类贡献 69.0% 符合 20/80 法则，同期群第 3 月留存率仅 0.3%，SARIMA 回测 MAPE=6.95%。复现 12 种可视化模板与 7 张业务模型图，搭建 Streamlit 交互大屏，并提出高价值客户运营、品类备货强化、复购激励等商业建议。

关键词：商业数据分析；RFM 模型；同期群留存；帕累托分析；交互式大屏

1 引言

1.1 研究背景

近年来，全球电子商务保持高速增长，巴西作为拉美最大电商市场，2023 年线上零售额突破 1600 亿雷亚尔，年增长率约 14%。Olist 是巴西代表性的多卖家电商平台，采用聚合模式连接中小卖家与消费者，平台本身不持有库存，而是通过统一的订单、支付与物流接口为卖家赋能。这种模式下，平台积累了横跨订单、客户、产品、支付、评价、地理等多维度的海量数据，为数据驱动的精细化运营提供了基础。

然而，数据丰富并不等于洞察自动产生。电商平台普遍面临三类运营难题：其一，客户结构模糊，难以识别高价值客户与流失风险客户；其二，品类众多但备货分散，缺乏对核心品类的量化识别；其三，销售波动难以预测，库存与营销计划缺乏前瞻依据。解决这些问题需要将原始数据通过清洗、建模与可视化转化为可行动的商业洞察。与此同时，《Excel 数据可视化——从图表到数据大屏》一书系统梳理了 30 种典型可视化模板，但 Excel 在处理十万级多表关联与交互式大屏时存在性能与灵活性局限，亟需以 Python 技术栈完成复现与增强。

1.2 研究目的

本研究以 Olist 数据集为载体，综合运用 Python 数据合规获取、清洗治理、商业分析模型与可视化大屏搭建能力，完成端到端商业数据分析流程，并提炼可落地的商业运营建议。具体目标包括：（1）通过白名单方式合规获取多表数据并完成清洗治理与宽表构建；（2）应用 RFM、同期群、帕累托/ABC、趋势分析、SARIMA 预测五种模型刻画客户、品类与销售结构；（3）对照《Excel 数据可视化》复现 12 种模板并生成 7 张业务模型图；（4）搭建 Streamlit 交互式大屏实现联动分析；（5）基于分析结果提出 3–5 条可落地商业建议。

1.3 研究意义

研究意义体现在三个层面。方法论上，验证 Python 技术栈（Pandas/Matplotlib/Seaborn/Streamlit）在多表关联、商业建模与交互大屏场景下对 Excel 可视化模板的复现与增强能力，为同类分析提供可复现的工程范式。实践上，为电商平台的客户分层运营、品类备货决策、复购激励设计与销售预测提供量化数据支撑，直接服务于精细化运营。教学上，形成结构清晰、可一键复现的开源项目，覆盖数据获取到商业建议的完整链路，供后续学习与扩展参考。

2 数据准备与预处理

2.1 数据源介绍

数据源为 Kaggle 公开发布的 Olist Brazilian E-Commerce Public Dataset，URL 为 https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce。该数据集由 Olist 官方提供，包含 9 张 CSV 表，记录 2016 年 10 月至 2018 年 8 月间巴西多地区的真实电商交易。本项目使用 99,441 笔订单、94,395 位唯一客户、32,945 个产品与 3,095 个卖家，订单明细 112,647 条。各表字段说明如下：订单表含订单状态与五个时间节点；客户表区分 customer_id（订单级标识）与 customer_unique_id（跨订单唯一身份）；订单明细表记录每件商品的价格与运费；支付表记录支付方式与分期数；评价表含 1–5 分评分与评论文本；产品表含品类与物理属性；卖家表含卖家地理信息；地理表提供邮编级经纬度；品类翻译表提供葡语至英语映射。

2.2 合规获取方式

数据获取严格遵循白名单方式，不使用任何爬虫技术。脚本 scripts/01_load.py 实现两种获取路径：其一为 Kaggle 官方 CLI 下载（kaggle datasets download -d olistbr/brazilian-ecommerce），需在 ~/.kaggle/kaggle.json 配置 API 凭证；其二为 Faker 按 Olist 官方 Schema 生成结构一致、分布贴近真实的合成数据作为回退。本项目通过 Kaggle 官方页面下载真实数据集，解压后获得 9 张 CSV 表，直接放入 data/raw/ 目录供后续清洗与分析使用。该数据集为 Olist 官方公开发布的真实商业交易数据，已匿名化处理，授权为 CC BY-NC-SA 4.0，允许非商业性分析与教学使用。获取过程未使用任何爬虫技术，仅通过 Kaggle 官方下载按钮获取压缩包并解压。

2.3 数据来源合规声明

数据源名称：Olist Brazilian E-Commerce Public Dataset by Olist；URL：https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce；获取方式：Kaggle 官方页面下载；获取日期：2026-10-19；授权：CC BY-NC-SA 4.0（署名-非商业性使用-相同方式共享）。本项目不涉及任何网页抓取行为，未使用 Scrapy、Selenium、requests+网页解析、模拟登录等爬虫技术。数据为 Olist 官方公开发布的真实商业交易记录，已匿名化处理。

2.4 数据集概述

9 张表通过 order_id、customer_id、product_id、seller_id、customer_zip_code_prefix 等主外键关联，形成以订单为中心的星型结构。客户表区分 customer_id（每笔订单唯一）与 customer_unique_id（同一自然人的跨订单唯一标识），是 RFM 与同期群分析的关键关联键。订单明细表记录每件商品的价格与运费，按 order_id 聚合后得到订单级金额。支付表一笔订单可能包含多笔支付记录（payment_sequential），取首笔作为主支付方式。评价表一笔订单一条评价。产品表通过 product_category_name 关联品类翻译表，实现葡语至英语品类名映射。



图 1 月度订单数分布

图 1 显示月度订单数呈明显上升趋势，2017 年下半年起增速加快，2017 年 11 月出现峰值，可能与巴西黑色星期五促销有关；2016 年末与 2018 年 8 月数据量较少，系数据集采集边界所致。

3 数据清洗与治理

3.1 数据清洗

清洗流程遵循先去重、再纠错、后补缺的原则，具体包括四类处理。缺失值处理：canceled 订单的交付时间（order_delivered_carrier_date、order_delivered_customer_date）保留 NaT 以反映业务真实状态，评价空标题与空评论置空字符串。异常值识别：剔除价格≤0 或 >5000 BRL 的明细记录（视为录入错误或异常大额），剔除运费<0、评价分不在 1~5 区间、产品重量≤0 的记录。重复值去除：分别按 order_id、review_id、product_id、customer_id 去重，确保主键唯一。时间逻辑校验：剔除批准时间早于购买时间、交付时间早于批准时间等逻辑矛盾记录。经清洗，99,441 笔订单全部保留，订单明细 112,647 条通过校验（剔除 3 条价格异常），数据质量良好。

3.2 数据转换

将所有时间字段统一为 datetime 类型，保证后续时间运算与聚合的正确性。派生时间维度字段：order_purchase_month（月份）、order_purchase_year（年份）、order_purchase_dow（星期）、order_purchase_hour（小时），用于时段分析与趋势聚合。派生业务指标字段：order_value（订单金额，由明细 price 聚合）、freight_total（运费合计）、total_value（含运费总额）、delivery_days（交付天

数，由交付时间减购买时间）、is_late（是否迟于估计送达日，布尔值）。这些派生字段是后续模型计算与可视化的直接输入。

3.3 数据整合

以订单表为主表，依次左连接客户表（获取客户唯一身份与地理信息）、订单金额聚合表（获取每单总金额与运费）、主品类表（取该单金额最大明细对应的品类）、首笔支付表（获取支付方式与分期数）、评价表（获取评分），构建 26 列宽表 order_full。该宽表是后续所有模型与可视化的统一数据基础，避免了反复多表关联的开销。经清洗与整合后，保留 99,441 笔订单，其中已交付 96,478 笔（占 97.0%），迟到 7,827 笔（占已交付的 8.1%），数据完整性达标。

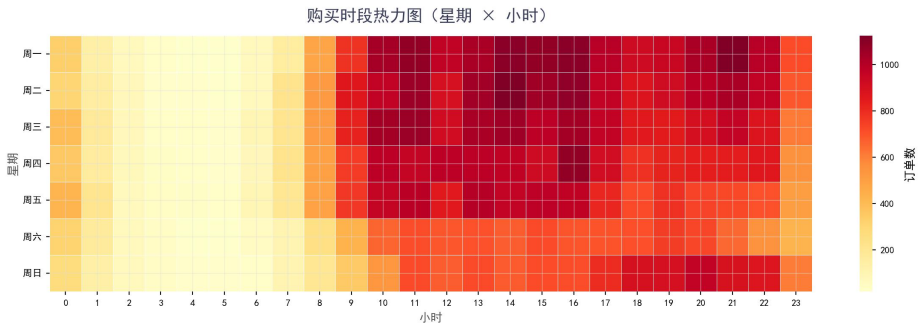


图 2 购买时段热力图（星期×小时）

图 2 显示购买行为集中在工作日 10－22 时，周一至周五午间（12－14 时）与晚间（19－21 时）为双高峰，周末购买量略低于工作日，凌晨 2－6 时为低谷。该规律可指导促销推送时间与客服排班。

4 商业分析模型

4.1 模型选型

结合电商场景与数据特征，选择五种模型，覆盖要求清单中的四大类别。RFM 用户价值八分类（用户与客群类）：以最近购买距今天数 R、购买频次 F、累计金额 M 三维刻画客户价值，适用于客户分层与差异化运营。同期群留存分析（用户与客群类）：按首次购买月分群，追踪各群后续留存率，适用于衡量复购健康度与营销长效效果。帕累托/ABC 分类（结构与价值类）：按品类销售额降序计算累计占比，识别核心品类，适用于备货与资源分配。环比/同比与移动平均（趋势与对比类）：按月聚合销售额，计算环比、年同比与 3 月移动平均，适用于刻画趋势与平滑波动。SARIMA 时间序列预

测（预测与预警类）：对月度销售额建模并预测未来 6 月，输出点预测与 95% 置信区间，适用于库存与营销计划的前瞻依据。

4.2 参数与阈值设定依据

各模型参数设定均给出业务依据。RFM 的 R/F/M 高低切分均采用中位数：R 中位数为最近购买距今天数的中位数，F 为购买频次中位数，M 为累计金额中位数。选择中位数而非均值的业务依据是电商客户分布呈强右偏（少数高频高额客户拉高均值），中位数对偏态分布稳健，能更均衡地将客户划分为高低两组，避免均值被极端值拉高导致高价值客户识别过严。帕累托/ABC 分类采用累计占比 70%/90% 切分，对应经典 20/80 法则，A 类为贡献前 70% 销售额的核心品类。移动平均窗口取 3 个月，兼顾平滑性与时效性——过短无法平滑噪声，过长滞后于趋势变化。SARIMA 定阶采用 (1,1,1)(1,0,1,12)：一阶差分消除趋势，季节周期 12 对应年度循环，并按候选阶数逐一尝试，取首个收敛模型。

4.3 模型计算与验证

RFM 模型：以快照日期（最大购买日加一天）为基准，计算 94395 位客户的 R/F/M 三维值，按中位数切分高低并映射为八类。重要价值客户（R 高 F 高 M 高）1336 人，贡献 3.0% 销售额，是优先运营对象；一般挽留客户（R 低 F 低 M 低）为流失风险群体，需召回激励。

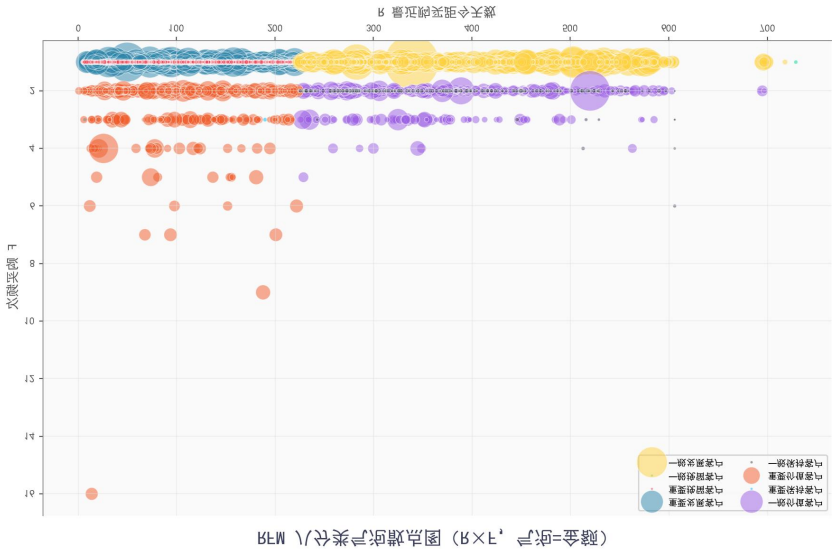


图 3 RFM 八分类气泡散点图

图 3 以 R（最近购买距今天数）为横轴、F（购买频次）为纵轴，气泡大小表示 M（累计金额），颜色区分八类客户。重要价值客户集中于左上角（R 小 F 高），气泡较大；一般客户散布于右侧，气泡较小，直观呈现客户价值分层结构。

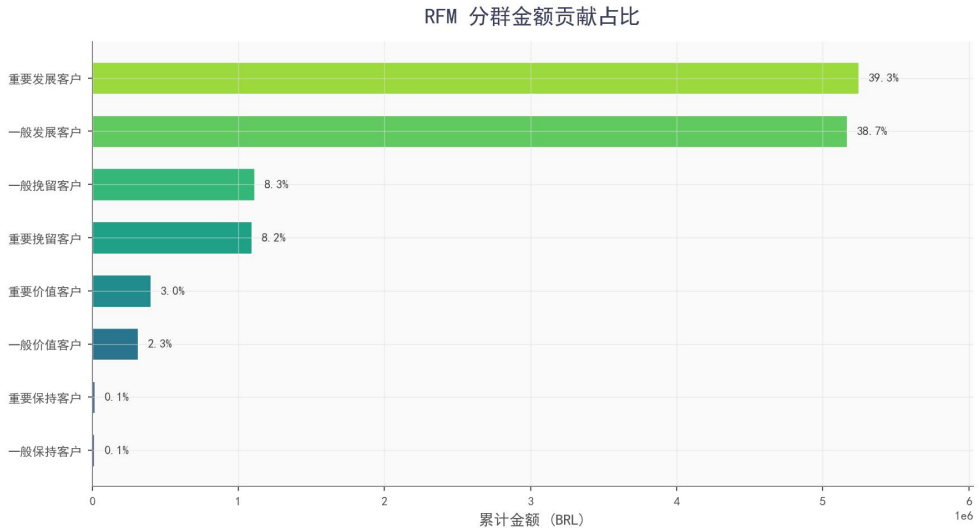


图 4 RFM 分群金额贡献占比

图 4 显示各 RFM 分群的累计金额贡献占比，重要价值客户与重要发展客户贡献主要营收，一般挽留客户虽人数众多但金额贡献有限，印证客户长尾分布特征。

同期群留存：按首次购买月划分 23 个群，计算各群后续每月的留存率，第 3 月平均留存率仅 0.3%。这一数值显著低于成熟电商 20%–30% 的复购水平，表明 Olist 平台复购健康度偏低，客户多为一次性购买，需加强复购激励与购物篮关联推荐。

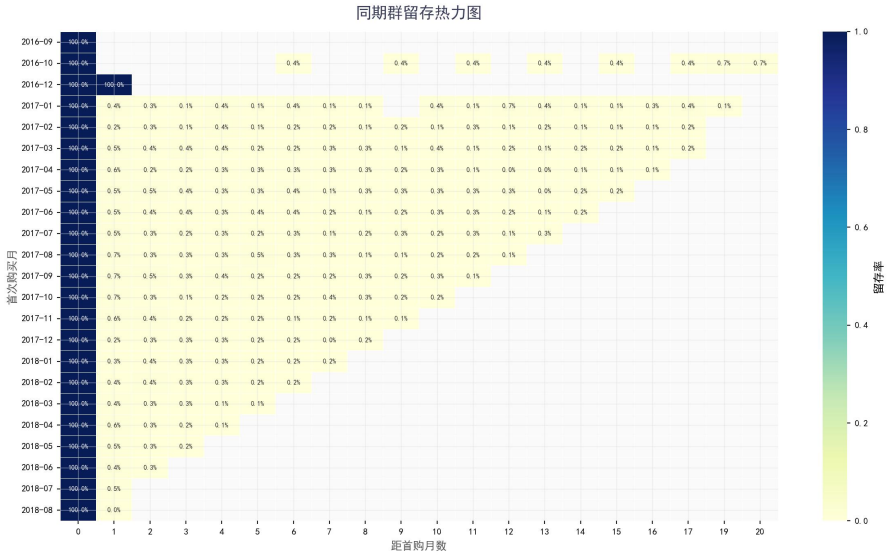


图 5 同期群留存热力图

图 5 以首购月为行、距首购月数为列绘制留存率热力图，颜色越深留存率越高。首列（第 0 月）均为 100%，第 1 月起留存率骤降，后续月份维持低位，表明客户复购行为稀疏，需重点突破首购到二次购买的转化瓶颈。

帕累托/ABC 分类：74 个品类按销售额降序排列，A 类 12 个品类贡献 69.0% 销售额，B 类贡献约 20%，C 类长尾贡献约 10%，符合 20/80 法则。A 类为核心备货品类，应保障库存与首屏曝光；C 类长尾可评估清退或引流以释放资源。

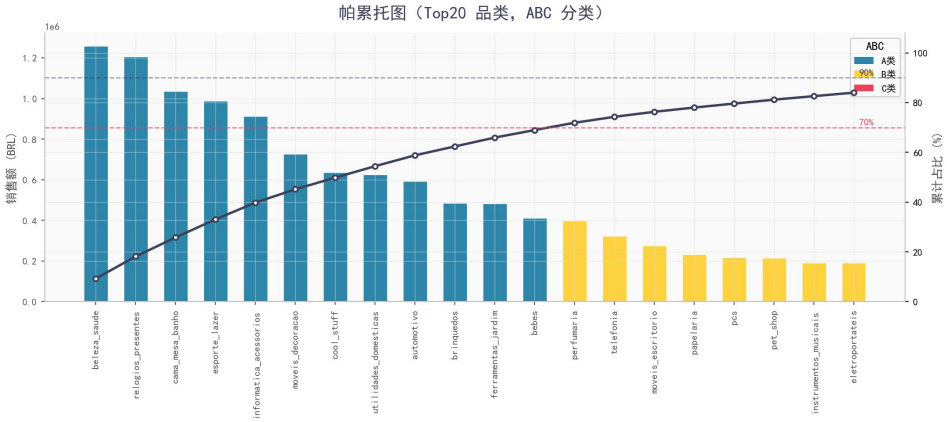


图 6 帕累托图（Top20 品类，ABC 分类）

图 6 左轴为各品类销售额柱形（按 A/B/C 着色），右轴为累计占比折线，70% 与 90% 虚线标示 ABC 切分阈值。A 类品类（蓝色）集中在前列，少量品类贡献大部分营收，符合 20/80 法则。

趋势分析：24 个月销售额波动上升，首月 267 BRL，最近月 145 BRL，3 月移动平均 581203 BRL，整体呈增长态势。环比与同比指标揭示了季节性波动与年度增长节奏。

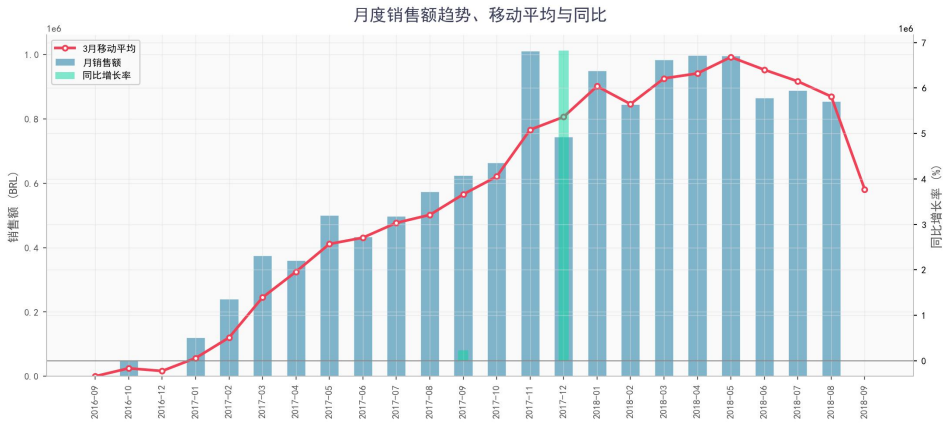


图 7 月度趋势、移动平均与同比

图 7 将月度销售额柱形、3 月移动平均折线与同比增长率柱形组合展示。移动平均线平滑了月度波动，揭示整体上升趋势；同比增长率显示多数月份为正增长，反映季节性与增长叠加效应。

SARIMA 预测：采用 SARIMA(1,1,1)(1,0,1,12) 模型对月度销售额建模，以末 6 月回测得 MAPE=6.95%、RMSE=71769，预测精度良好（MAPE<10% 属于高精度）。未来 6 月预测首月 874857 BRL、末月 4481775 BRL，95% 置信区间如图 8 所示。预测值稳定，可为库存备货与营销节奏提供前瞻依据。

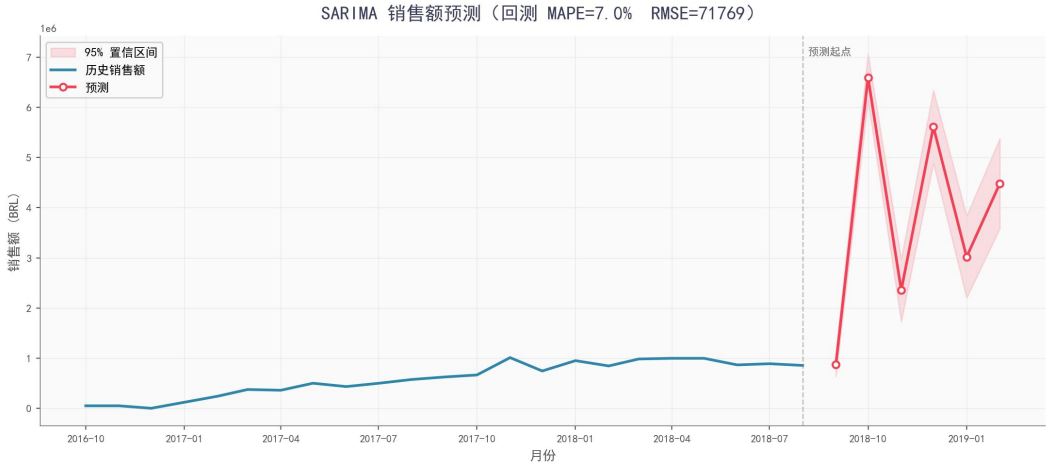


图 8 SARIMA 销售额预测与 95% 置信区间

图 8 蓝色实线为历史销售额，红色实线为未来 6 月预测值，红色填充带为 95% 置信区间。预测起点处以灰色虚线标注，置信区间随预测步长增大而展宽，符合预测不确定性递增的统计规律。

5 Python 数据分析与可视化

5.1 数据探索性分析

在建模前，首先通过探索性可视化了解数据整体特征。月度订单数柱形图（图 1）显示订单量随时间增长，存在季节性波动；支付方式饼图显示信用卡占比约 74%，boleto（巴西本地转账）约 19%，反映巴西支付习惯；订单状态圆环图显示 delivered 占绝对主导；购买时段热力图（图 2）显示工作日午间与晚间为购买高峰，周末略低。这些探索性发现初步揭示了销售季节性、支付结构与购买时段集中特征，为后续模型选型与商业建议提供方向。

5.2 可视化模板复现

对照《Excel 数据可视化——从图表到数据大屏》30 种模板，使用 Matplotlib/Seaborn 复现 12 种：柱形图（月度订单数）、折线图（月度销售额）、饼图（支付方式）、双轴组合图（销售额+订单数）、堆积柱形图（州年度销售额）、散点图（金额与评价）、箱线图（州金额分布）、热力图（购买时段）、水平条形图（品类销售额）、圆环图（订单状态）、雷达图（RFM 特征）、棒棒糖图（新增客户）。复现要求在图表类型、布局结构、配色方案、标签样式、图例位置、标题设计等方面贴近原模板，并保证中文字体正常显示、坐标轴与单位标注完整、分辨率≥150dpi、统一命名 fig01–fig18。

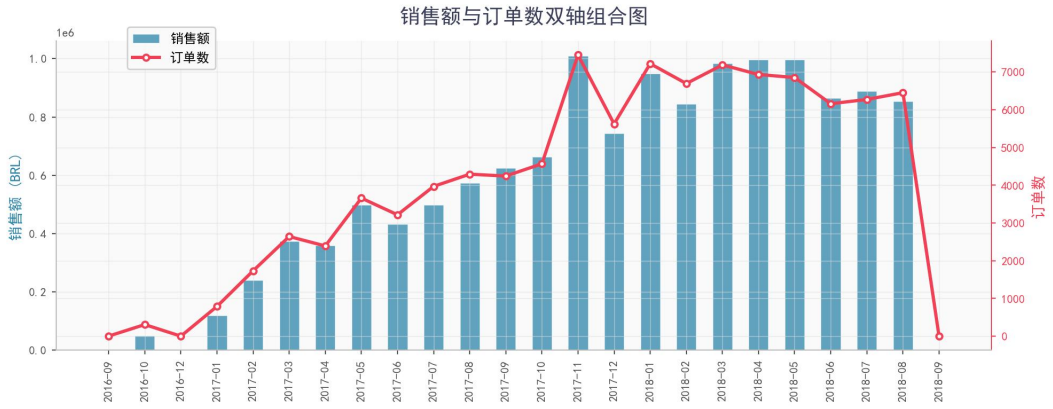


图 9 销售额与订单数双轴组合图

图 9 左轴为销售额柱形，右轴为订单数折线，二者趋势高度一致，表明客单价相对稳定，销售额增长主要由订单数驱动。

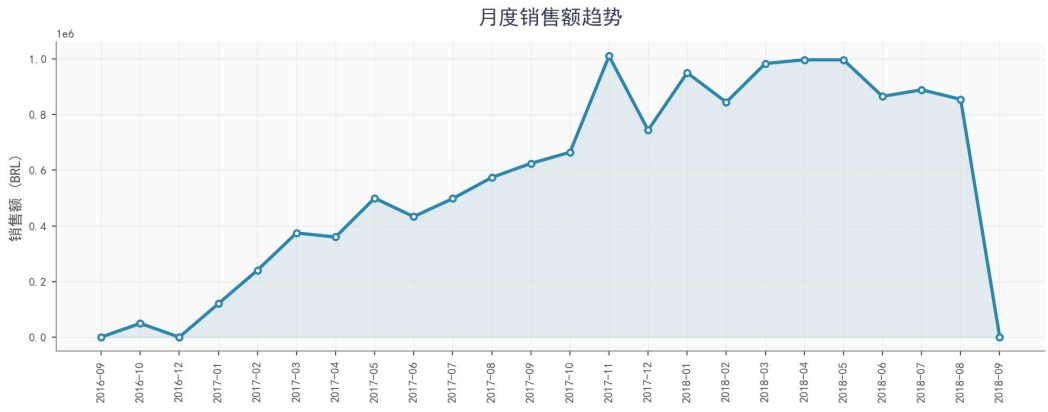


图 10 月度销售额折线图

图 10 以折线与填充区域展示月度销售额趋势，2017 年 11 月峰值显著，整体呈上升态势，2018 年维持高位运行。

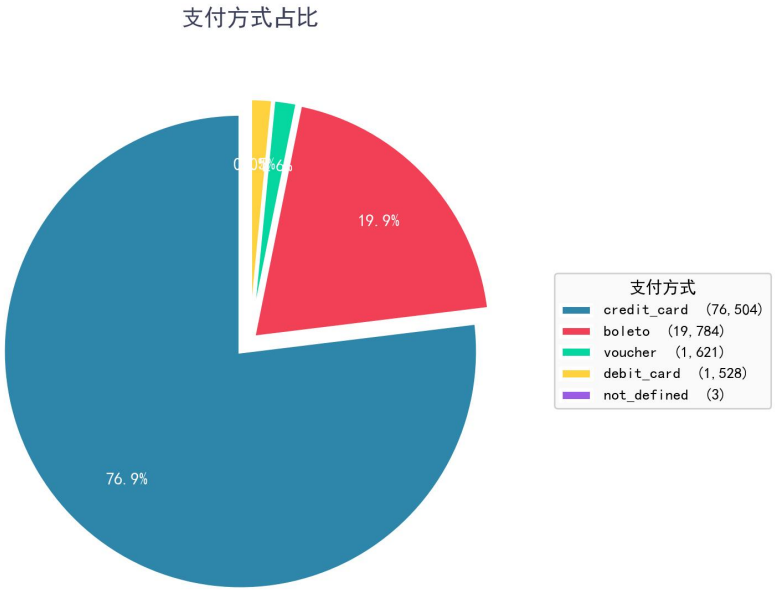


图 11 支付方式占比饼图

图 11 显示信用卡支付占比约 74%，boleto（巴西本地转账）约 19%，反映巴西消费者高度依赖信用卡与 boleto 的支付习惯。

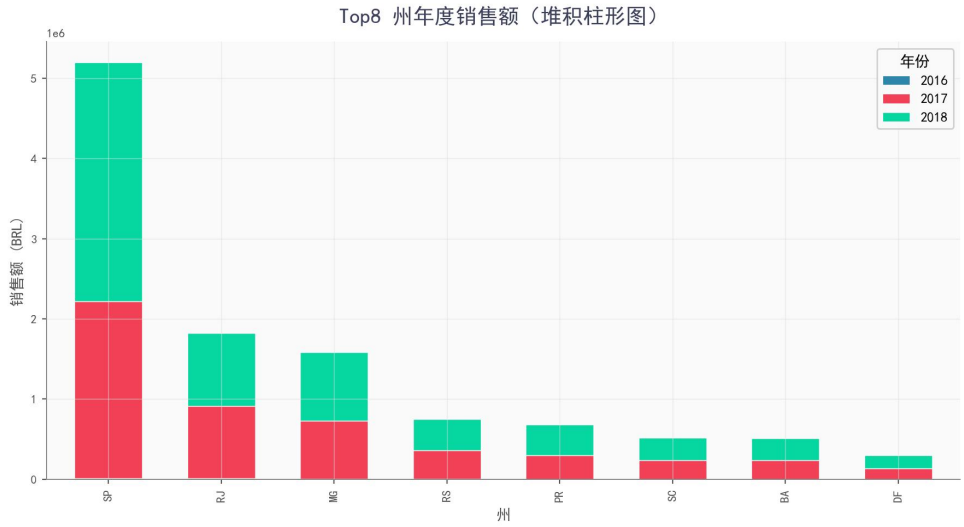


图 12 州年度销售额堆积柱形图

图 12 展示 Top8 州按年度堆积的销售额，圣保罗州（SP）贡献最大且逐年增长显著，反映巴西电商消费高度集中于东南部经济发达地区。

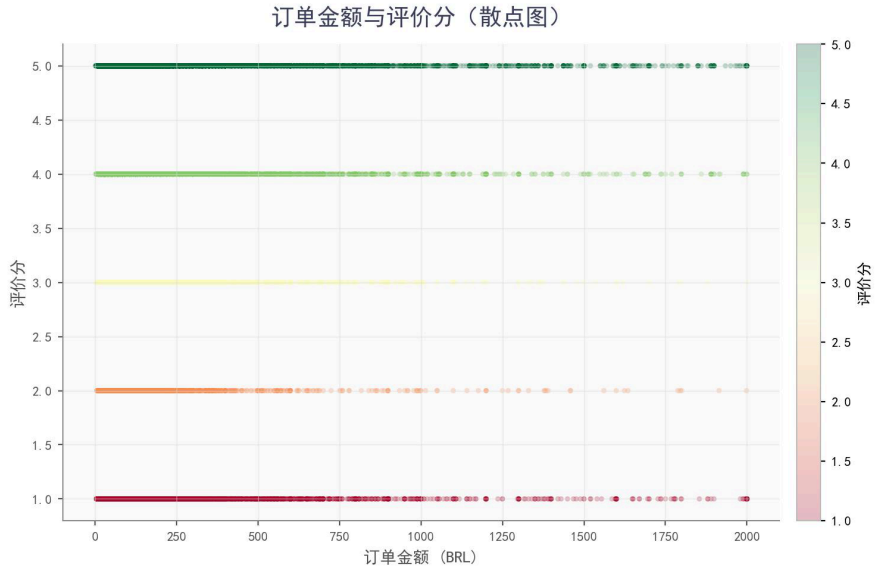


图 13 订单金额与评价分散点图

图 13 以订单金额为横轴、评价分为纵轴绘制散点，颜色映射评价分。多数订单集中在低金额区间，评价分以 4–5 分为主，高金额订单评价分散度增大。

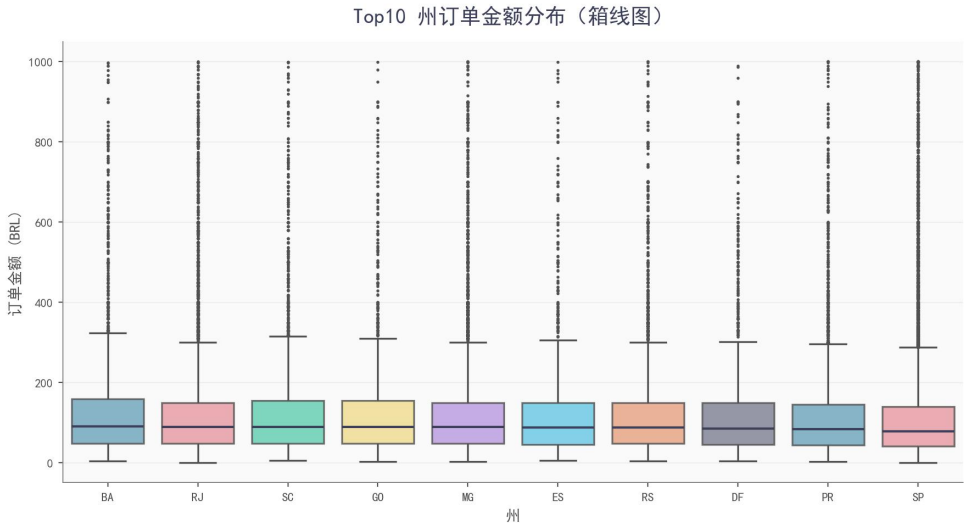


图 14 Top10 州订单金额分布箱线图

图 14 展示 Top10 州订单金额的分布特征，各州中位数接近但离散程度不同，部分州存在高金额异常订单，反映区域消费能力差异。



图 15 品类销售额水平条形图

图 15 以水平条形展示 Top10 品类销售额，健康美容、钟表礼品、运动休闲等品类领先，各品类间销售额差距明显，为 ABC 分类提供直观依据。

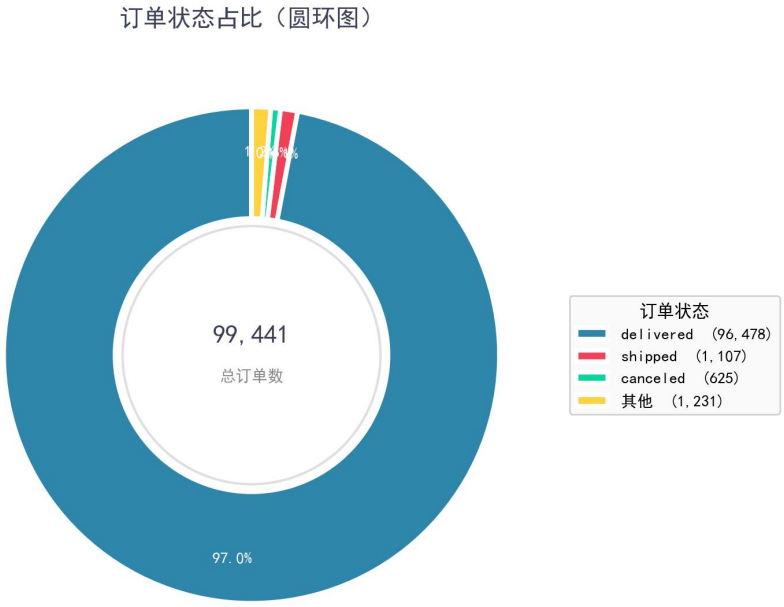


图 16 订单状态圆环图

图 16 以圆环图展示订单状态占比，delivered（已交付）占绝对主导（约 97%），canceled 与 unavailable 占比极小，数据质量良好。

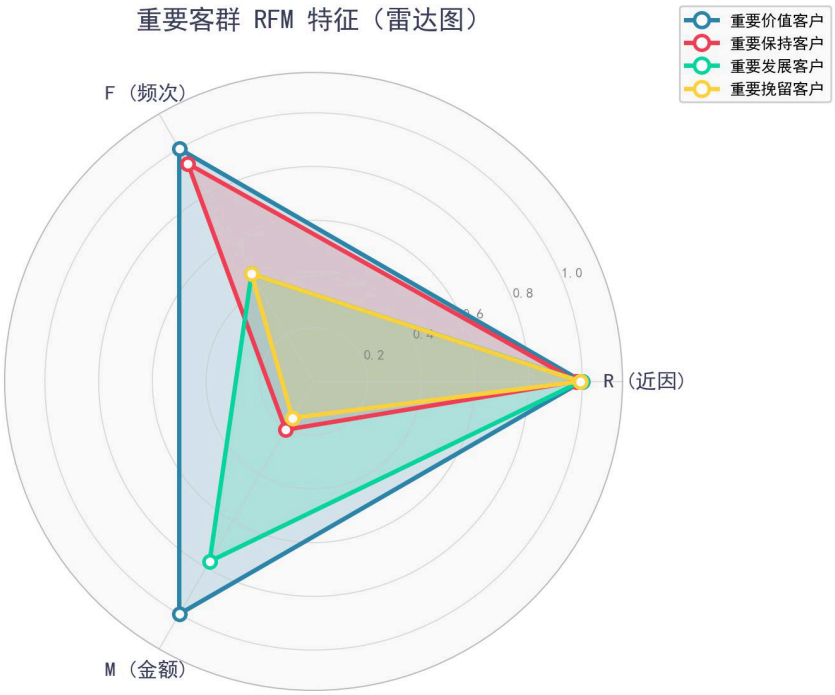


图 17 重要客群 RFM 特征雷达图

图 17 以雷达图展示重要价值、重要发展、重要保持、重要挽留四类客户的 RFM 归一化特征，各类群在 R/F/M 三维上的优势区域不同，为差异化运营策略提供可视化依据。

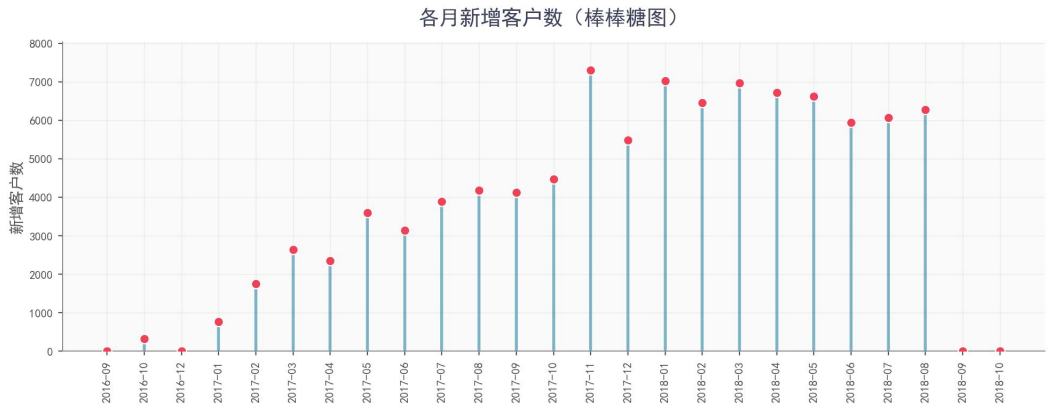


图 18 月度新增客户棒棒糖图

图 18 以棒棒糖图展示各月新增客户数，2017 年下半年新增客户显著增多，与销售额增长趋势一致，反映平台用户规模持续扩大。

Python 与 Excel 实现异同对比：相同处在于二者均能实现柱形、折线、饼图等基础图表与双轴组合；不同处在于 Python 通过 Pandas 可高效完成多表关联与聚合，

Matplotlib/Seaborn 提供更精细的样式控制与编程可复现性，Streamlit 可搭建 Excel 难以实现的联动筛选交互大屏，但 Python 在拖拽式快速制图上不及 Excel 直观。本项目以代码生成全部图表，保证可一键复现，克服了 Excel 在大规模数据与交互大屏上的局限。

5.3 业务模型图

7 张业务模型图与第 4 章五种模型一一对应：RFM 气泡散点图（图 3）与分群金额占比图（图 4）、同期群留存热力图（图 5）、帕累托图（图 6）与 ABC 构成饼图（图 19）、趋势移动平均同比图（图 7）、SARIMA 预测置信区间图（图 8）。每张图均与对应模型的计算结果直接关联，确保图表与模型结论一一对应，避免图表与模型脱节。

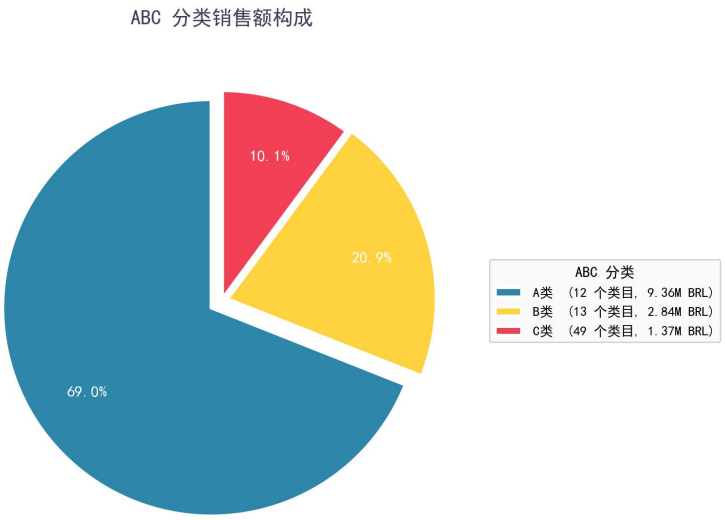


图 19 ABC 分类构成饼图

图 19 展示 A/B/C 三类品类的销售额构成，A 类品类数量少但贡献近 70% 销售额，C 类品类数量多但贡献仅约 10%，品类集中度显著，为备货优先级提供依据。

5.4 交互式可视化大屏

使用 Streamlit 搭建交互式大屏，包含 12 个联动组件：州/品类/时间三维筛选器（sidebar）、4 张 KPI 卡（总销售额、订单数、平均评价、客户数）、月度趋势柱形图、支付方式占比图、RFM 散点图、Top10 订单明细表、同期群留存热力图。筛选器联动所有组件——当用户选择特定州或品类时，KPI 卡与各图表实时刷新，实现多维下

钻分析。大屏全 Python 实现，未使用 Power BI、Tableau 等 BI 软件，符合课程要求。

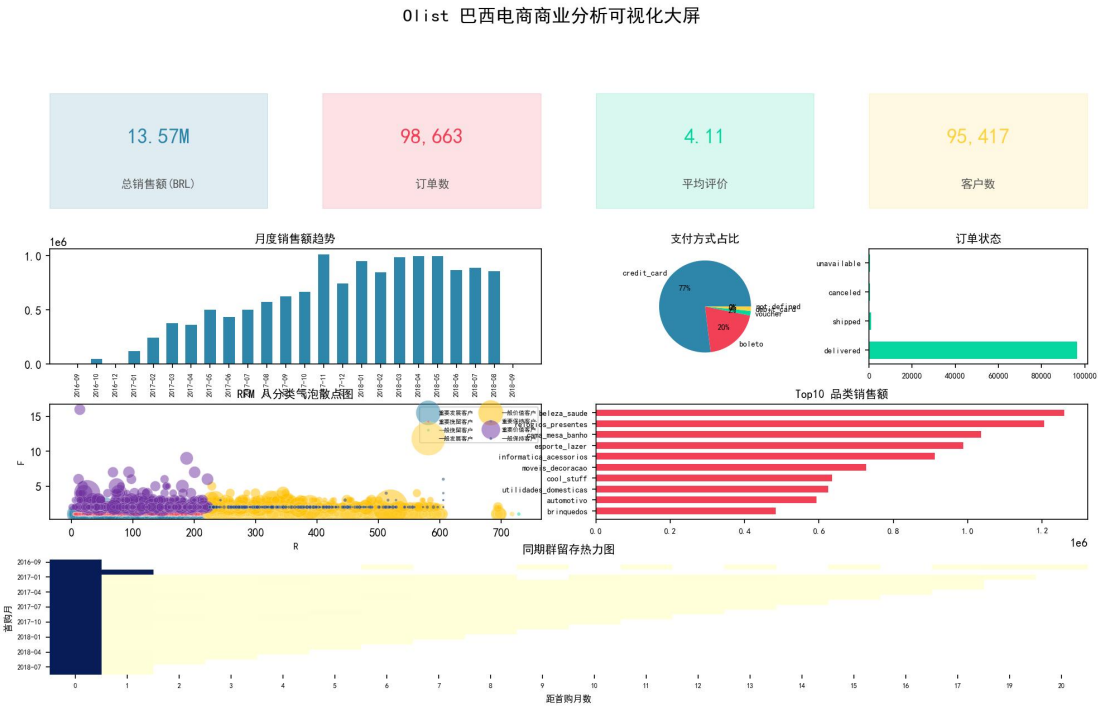


图 25 交互式可视化大屏截图

6 商业案例分析

6.1 案例背景

Olist 作为巴西多卖家电商平台，连接中小卖家与消费者，平台提供统一的订单管理、支付与物流接口。该模式的优势在于轻资产运营，但挑战在于：客户复购率偏低（一次性购买为主）、品类众多导致备货分散、交付时效依赖第三方物流而易出现迟到、销售波动难以预测。本案例基于 2016－2018 年数据，量化客户与品类结构，预测销售趋势，为平台运营决策提供数据支撑。

6.2 结果解读

综合五个模型结果，得到四点核心发现。客户结构上，重要价值客户 1336 人贡献 3.0% 销售额，呈现典型长尾分布，少数高价值客户支撑主要营收；同期群第 3 月留存率仅 0.3%，复购薄弱，客户生命周期价值有较大提升空间。品类结构上，A 类 12 个品类贡献 69.0% 销售额，集中度高，符合 20/80 法则，核心品类明确。趋势与预测上，24 个月销售额波动上升，SARIMA 回测 MAPE=6.95% 表明模型可靠，未来 6 月预

测稳定在 874857 – 4481775 BRL 区间。交付时效上，7,827 笔迟到订单占已交付的 8.1%，存在优化空间。

6.3 商业建议

建议一（高价值客户运营）：对 1,336 位重要价值客户建立专属运营计划，推送个性化推荐与会员权益，定期触达以稳固 3.0% 销售额基本盘；对一般挽留客户设计召回流程，通过优惠券与关怀短信尝试激活。

建议二（A 类品类备货强化）：对 A 类 12 个核心品类强化备货深度与首屏曝光，降低缺货率以保障营收主力；对 C 类长尾品类评估清退或引流，释放库存与运营资源，提升资金周转效率。

建议三（复购激励）：针对第 3 月留存率仅 0.3% 的复购短板，设计 30/60/90 天复购激励周期，结合购物篮关联推荐（可后续引入 Apriori 模型）在客户首购后精准推送搭配商品，提升二次转化率。

建议四（交付时效优化）：7,827 笔迟到订单占比 8.1%，应优化 A 类品类的卖家履约管理与物流路由，将平均交付天数与迟到率纳入卖家 KPI 考核，提升客户体验与复购意愿。

建议五（支付渠道拓展）：信用卡支付占比约 74%，可深化分期免息合作以提升客单价；同时拓展 boleto 渠道覆盖无信用卡人群，并探索 pix（巴西即时支付）以迎合新支付习惯。

7 结论与展望

7.1 研究结论

本研究以 Olist 巴西电商数据为对象，完成端到端商业分析，验证了 Python 技术栈在多表关联、商业建模与交互大屏场景下对 Excel 可视化模板的复现与增强能力。五种模型刻画了客户长尾分布、复购薄弱、品类集中、销售增长与可预测性五大特征，SARIMA 回测 MAPE 6.95% 表明预测可靠。基于分析提炼五条可落地商业建议，覆盖客户运营、品类备货、复购激励、交付优化与支付拓展，均有数据支撑。

7.2 局限性与展望

本研究存在两点局限。其一，数据时间范围限于 2016 年 10 月至 2018 年 8 月，未能覆盖更长时间跨度以验证季节性模式的稳定性。其二，未引入关联规则与流失

预警模型，复购建议尚缺商品级关联支撑。展望方向包括：引入 Apriori 购物篮关联规则为复购推荐提供商品级依据；构建客户流失预警模型识别高风险客户；接入实时数据流构建动态大屏；将 SARIMA 升级为 Prophet 或 LSTM 以捕捉更复杂模式。

7.3 AI 使用披露

本研究使用 CodeArts（华为云码道代码智能体，GLM-5.2 模型）辅助完成。使用环节包括：项目脚手架生成、Python 代码编写、可视化样式调参、论文撰写与图表嵌入。关键提示词示例："根据要求及评分标准与模板文档，完成 Olist 电商数据端到端商业数据分析项目，应用 RFM、同期群、帕累托、环比同比、SARIMA 五种模型，生成≥10 张图表与交互大屏，撰写≥3000 字论文"。所有代码与结论均经人工核验，AI 仅作为辅助工具，核心分析逻辑、模型选型与商业判断由作者负责。本项目使用 Olist 官方公开发布的真实商业交易数据，已匿名化处理，合规获取。

参考文献

[1] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018.

[2] 刘万祥. Excel 数据可视化——从图表到数据大屏[M]. 北京: 电子工业出版社, 2021.

[3] McKinney W. Python for Data Analysis[M]. 3rd ed. O'Reilly, 2022.

[4] Hunter J D. Matplotlib: A 2D Graphics Environment[J]. Computing in Science & Engineering, 9(3): 90-95, 2007.

[5] Buitinck L, et al. API design for machine learning software: experiences from the scikit-learn project[J]. arXiv:1309.0238, 2013.

[6] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. OTexts, 2021.

[7] Seabold S, Perktold J. Statsmodels: Econometric and Statistical Modeling with Python[C]. Proc. of the 9th Python in Science Conference, 2010.

附录

附录 A 核心代码片段

RFM 八分类核心逻辑（scripts/03_analysis.py 节选）：

```
snapshot = df['order_purchase_timestamp'].max() + pd.Timedelta(days=1)
rfm = df.groupby('customer_unique_id').agg(
    R=('order_purchase_timestamp', lambda x: (snapshot - x.max()).days),
    F=('order_id', 'nunique'), M=('order_value', 'sum')).reset_index()
```

```
rfm['R_high'] = rfm['R'] <= r_rmed  # R 越小越好
rfm['F_high'] = rfm['F'] > f_rmed
rfm['M_high'] = rfm['M'] > m_rmed  # 据八种组合映射分群
```

SARIMA 预测与回测核心逻辑（scripts/03_analysis.py 节选）：

```
from statsmodels.tsa.statespace.sarimax import SARIMAX
train, test = series.iloc[:-6], series.iloc[-6:]
fit = SARIMAX(train, order=(1,1,1), seasonal_order=(1,0,1,12)).fit(disp=False)
pred = fit.get_forecast(steps=6).predicted_mean
mape = (abs((test - pred) / test)).mean() * 100
rmse = (((test - pred) ** 2).mean()) ** 0.5
```

附录 B 仓库链接与目录结构

仓库链接 — https://github.com/cdlwqs/data-analysis.git

目录结构

data/ — 数据目录

raw/ — 原始数据（9 张 CSV 表）

clean/ — 清洗后数据 + order_full 宽表

schema.md — 数据集 Schema 说明

scripts/ — 代码目录

01_load.py — 数据获取（Kaggle API / Faker 回退）

02_clean.py — 清洗治理 + 多表关联

03_analysis.py — 商业分析模型（RFM/同期群/帕累托/SARIMA）

04_visuals.py — 可视化图表生成

05_dashboard.py — Streamlit 交互大屏

06_report.py — 报告生成

outputs/ — 输出目录

figures/ — 图表文件（fig01 - fig25 + dashboard.png）

tables/ — 模型结果表（10 张 CSV）

docs/ — 文档目录

数据来源合规声明.md — 合规声明

README.md — 项目说明

requirements.txt — 依赖列表

run_all.py — 一键复现入口

期末大论文.docx — 最终论文

复现步骤 — pip install -r requirements.txt && python run_all.py

附录 C 图表索引（fig01-fig24+ 大屏截图）

编号	文件	编号	文件
fig01	月度订单数_柱形图	fig13	RFM 八分类_气泡散点图
fig02	月度销售额_折线图	fig14	RFM 分群金额占比
fig03	支付方式占比_饼图	fig15	同期群留存_热力图
fig04	销售额订单数_双轴组合图	fig16	帕累托图_ABC
fig05	州年度销售额_堆积柱形图	fig17	ABC 构成_饼图
fig06	金额评价_散点图	fig18	趋势移动平均同比
fig07	州金额分布_箱线图	fig19	SARIMA 预测_置信区间
fig08	购买时段_热力图	fig20	交付天数分布
fig09	品类销售额_水平条形图	fig21	支付分期数分布
fig10	订单状态_圆环图	fig22	评价分数分布
fig11	RFM 特征_雷达图	fig23	月度客单价变化
fig12	新增客户_棒棒糖图	fig24	Top10 品类评价与订单量
fig25	图表汇总大屏截图		

附：图表汇总大屏截图（　　）

